

Solución Taller 1: Preprocesamiento y visualización de datos

UNIVERSIDAD DEL VALLE – FACULTAD DE INGENIERIA

Machine Learning para Gestión Financiera

Profesor: Ivan Mauricio Bermúdez Vera

Estudiantes: Valeria Saldaña - Juan Chacón - Jhon Tascón

Introducir...

0. Carga del conjunto de datos

El conjunto de datos German Credit presenta información sobre 1000 solicitantes de crédito. Cada variable en el conjunto permite una aproximación a las características financieras y socioeconómicas del potencial cliente a su vez que permite construir un análisis de estas variables con respecto a su comportamiento crediticio.

```
##      V1 V2  V3  V4   V5  V6  V7 V8  V9  V10 V11  V12 V13  V14  V15 V16  V17 V18
## 1 A11  6 A34 A43 1169 A65 A75  4 A93 A101  4 A121  67 A143 A152  2 A173  1
## 2 A12 48 A32 A43 5951 A61 A73  2 A92 A101  2 A121  22 A143 A152  1 A173  1
## 3 A14 12 A34 A46 2096 A61 A74  2 A93 A101  3 A121  49 A143 A152  1 A172  2
## 4 A11 42 A32 A42 7882 A61 A74  2 A93 A103  4 A122  45 A143 A153  1 A173  2
## 5 A11 24 A33 A40 4870 A61 A73  3 A93 A101  4 A124  53 A143 A153  2 A173  2
## 6 A14 36 A32 A46 9055 A65 A73  2 A93 A101  4 A124  35 A143 A153  1 A172  2
##      V19  V20 V21
## 1 A192 A201  1
## 2 A191 A201  2
## 3 A191 A201  1
## 4 A191 A201  1
## 5 A191 A201  2
## 6 A192 A201  1
```

Como se logra evidenciar en la escritura anterior, hay registros que están codificados, además de que no se tienen el nombre de las columnas. En la siguiente sección, se realizará la limpieza y el preprocesamiento de los datos.

1. Diagnóstico de calidad de datos

Se asignaron nombres descriptivos a las 21 variables del conjunto de datos German Credit con el fin de facilitar su interpretación y análisis posterior.

Variable	Descripción
checking_status	Estado de la cuenta corriente
duration	Duración del crédito (meses)
credit_history	Historial crediticio
purpose	Propósito del crédito
credit_amount	Monto del crédito
savings	Cuenta de ahorros / bonos
employment	Antigüedad laboral
installment_rate	Tasa de cuota respecto al ingreso disponible
personal_status_sex	Estado civil y sexo
other_debtors	Otros deudores o garantes
residence_since	Tiempo de residencia actual
property	Tipo de propiedad
age	Edad
other_installment_plans	Otros planes de pago
housing	Tipo de vivienda
existing_credits	Número de créditos existentes en

este banco | | job | Ocupación | | people_liable | Número de personas a cargo | | telephone | Disponibilidad de teléfono | | foreign_worker | Trabajador extranjero | | default | Variable objetivo (Good / Bad) |

Se inicia verificando la estructura general de los datos, en los que se presentan 1000 observaciones y 20 variables. A continuación se presentan los tipos de variables donde se identifican 13 variables tipo caracter y 7 variables numéricas:

```
## 'data.frame': 1000 obs. of 21 variables:
## $ checking_status : chr "A11" "A12" "A14" "A11" ...
## $ duration : int 6 48 12 42 24 36 24 36 12 30 ...
## $ credit_history : chr "A34" "A32" "A34" "A32" ...
## $ purpose : chr "A43" "A43" "A46" "A42" ...
## $ credit_amount : int 1169 5951 2096 7882 4870 9055 2835 6948 3059 5234 ...
## $ savings : chr "A65" "A61" "A61" "A61" ...
## $ employment : chr "A75" "A73" "A74" "A74" ...
## $ installment_rate : int 4 2 2 2 3 2 3 2 2 4 ...
## $ personal_status_sex : chr "A93" "A92" "A93" "A93" ...
## $ other_debtors : chr "A101" "A101" "A101" "A103" ...
## $ residence_since : int 4 2 3 4 4 4 4 2 4 2 ...
## $ property : chr "A121" "A121" "A121" "A122" ...
## $ age : int 67 22 49 45 53 35 53 35 61 28 ...
## $ other_installment_plans : chr "A143" "A143" "A143" "A143" ...
## $ housing : chr "A152" "A152" "A152" "A153" ...
## $ existing_credits : int 2 1 1 1 2 1 1 1 1 2 ...
## $ job : chr "A173" "A173" "A172" "A173" ...
## $ people_liable : int 1 1 2 2 2 2 1 1 1 1 ...
## $ telephone : chr "A192" "A191" "A191" "A191" ...
## $ foreign_worker : chr "A201" "A201" "A201" "A201" ...
## $ default : int 1 2 1 1 2 1 1 1 1 2 ...
```

Se procede a convertir las variables categóricas a sus respectivas equivalencias denotadas en los atributos compartidos, a su vez que se convierte a formato factor:

```
## Rows: 1,000
## Columns: 21
## $ checking_status <fct> less_0, 0_200, no_account, less_0, less_0, no_~
## $ duration <int> 6, 48, 12, 42, 24, 36, 24, 36, 12, 30, 12, 48,~
## $ credit_history <fct> critical_other, existing_paid, critical_other,~
## $ purpose <fct> radio_tv, radio_tv, education, furniture equip~
## $ credit_amount <int> 1169, 5951, 2096, 7882, 4870, 9055, 2835, 6948~
## $ savings <fct> unknown, less_100, less_100, less_100, less_10~
## $ employment <fct> greater_7, 1_4, 4_7, 4_7, 1_4, 1_4, greater_7,~
## $ installment_rate <int> 4, 2, 2, 2, 3, 2, 3, 2, 4, 3, 3, 1, 4, 2, 4~
## $ personal_status_sex <fct> male_single, female_divorced_separated_married~
## $ other_debtors <fct> none, none, none, guarantor, none, none, none,~
## $ residence_since <int> 4, 2, 3, 4, 4, 4, 4, 2, 4, 2, 1, 4, 1, 4, 4, 2~
## $ property <fct> real_estate, real_estate, real_estate, buildin~
## $ age <int> 67, 22, 49, 45, 53, 35, 53, 35, 61, 28, 25, 24~
## $ other_installment_plans <fct> none, none, none, none, none, none, none, none~
## $ housing <fct> own, own, own, for_free, for_free, for_free, o~
## $ existing_credits <int> 2, 1, 1, 1, 2, 1, 1, 1, 1, 2, 1, 1, 1, 2, 1, 1~
## $ job <fct> skilled_official, skilled_official, unskilled_~
## $ people_liable <int> 1, 1, 2, 2, 2, 2, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1~
## $ telephone <fct> yes, none, none, none, none, none, yes, none, yes, n~
```

```
## $ foreign_worker      <fct> yes, yes, yes, yes, yes, yes, yes, yes, yes, y~
## $ default             <fct> good, bad, good, good, bad, good, good, good, ~
```

Ahora, una vez realizada la recodificación, se realiza un resumen estadístico de las variables a analizar.

Table 1: Resumen estadístico

[illegible]

analizar...

Una vez realizado el resumen estadístico, se procede a verificar si los datos numéricos y categóricos cumplen con sus características de validación que se describen a continuación:

```
## Object of class 'validator' with 21 elements:
## V01: german[["duration"]] > 0
## V02: german[["credit_amount"]] > 0
## V03: german[["installment_rate"]] > 0
## V04: german[["residence_since"]] > 0
## V05: german[["age"]] > 0
## V06: german[["existing_credits"]] >= 0
## V07: german[["people_liable"]] >= 0
## V08: checking_status %in% unname(dict_mapping[["checking_status"]])
## V09: credit_history %in% unname(dict_mapping[["credit_history"]])
## V10: purpose %in% unname(dict_mapping[["purpose"]])
## V11: savings %in% unname(dict_mapping[["savings"]])
## V12: employment %in% unname(dict_mapping[["employment"]])
## V13: personal_status_sex %in% unname(dict_mapping[["personal_status_sex"]])
## V14: other_debtors %in% unname(dict_mapping[["other_debtors"]])
## V15: property %in% unname(dict_mapping[["property"]])
## V16: other_installment_plans %in% unname(dict_mapping[["other_installment_plans"]])
## V17: housing %in% unname(dict_mapping[["housing"]])
```

```
## V18: job %in% unname(dict_mapping[["job"]])
## V19: telephone %in% unname(dict_mapping[["telephone"]])
## V20: foreign_worker %in% unname(dict_mapping[["foreign_worker"]])
## V21: default %in% unname(dict_mapping[["default"]])
```


Se definen cuántas filas presentan al menos una regla incumplida y se encuentra que el número es cero.

```
## integer(0)
```

A su vez, se encuentra que el número de datos faltantes en toda la base es igualmente cero.

```
sum(is.na(german))
```

```
## [1] 0
```




Una vez se revisan los datos faltantes, se procede a realizar un análisis de anomalías. Para ello, usamos el *criterio Tukey*:

Table 2: Detección de valores atípicos mediante el criterio de Tukey

Variable	Q1	Q3	IQR	Limite_Inferior	Limite_Superior	Atipicos	Porcentaje
duration	12.0	24.00	12.00	-6.00	42.00	70	7.0
credit_amount	1365.5	3972.25	2606.75	-2544.62	7882.38	72	7.2
installment_rate	2.0	4.00	2.00	-1.00	7.00	0	0.0

Variable	Q1	Q3	IQR	Limite_Inferior	Limite_Superior	Atipicos	Porcentaje
residence_since	2.0	4.00	2.00	-1.00	7.00	0	0.0
age	27.0	42.00	15.00	4.50	64.50	23	2.3
existing_credits	1.0	2.00	1.00	-0.50	3.50	6	0.6
people_liable	1.0	1.00	0.00	1.00	1.00	155	15.5


Detección de valores atípicos según el criterio de Tukey




```
## # A tibble: 326 x 3
##   Variable  Fila Valor
##   <chr>    <int> <int>
## 1 duration      2    48
## 2 duration     12    48
## 3 duration     30    60
## 4 duration     36    45
## 5 duration     37    48
## 6 duration     45    48
## 7 duration     64    48
## 8 duration     79    54
## 9 duration     96    54
##10 duration    116    48
## # i 316 more rows
```

Con base en los boxplots y el criterio Tukey... Sin embargo, a continuación se realiza los diagramas de dispersión de las variables numéricas y un análisis multivariado para evidenciar si hay algunas anomalías que son influyentes a nivel multivariable.


Análisis de Variables Numéricas



Distancia de Mahalanobis



Local Outlier Factor (LOF)




n_out_mahalanobis	n_out_lof
35	10

Analizar y decir que, a pesar de que los métodos dicen que hay ciertas anomalías en los datos, estos no parecen ser errores, y en los scatterplots no se evidencian inconsistencias.

2. Análisis exploratorio

Distribución de la variable objetivo (default)



Análisis descriptivo de variables cuantitativas


Se presenta inicialmente los estadísticos descriptivos de las variables numéricas:

Table 3: Estadísticos descriptivos de las variables numéricas

	Media	Mediana	Desv_Est	Minimo	Maximo
duration	20.90	18.0	12.06	4	72
credit_amount	3271.26	2319.5	2822.74	250	18424
installment_rate	2.97	3.0	1.12	1	4
residence_since	2.85	3.0	1.10	1	4
age	35.55	33.0	11.38	19	75

	Media	Mediana	Desv_Est	Minimo	Maximo
existing_credits	1.41	1.0	0.58	1	4
people_liable	1.16	1.0	0.36	1	2

Distribución de variables numéricas



Análisis descriptivo de variables categóricas

Table 4: Resumen descriptivo de variables categóricas

Variable	Categorías	Moda	Frecuencia_moda
checking_status	4	no_account	394
credit_history	5	existing_paid	530
purpose	10	radio_tv	280
savings	5	less_100	603
employment	5	1_4	339
personal_status_sex	4	male_single	548
other_debtors	3	none	907
property	4	car_or_other	332
other_installment_plans	3	none	814
housing	3	own	713
job	4	skilled_official	630
telephone	2	none	596
foreign_worker	2	yes	963

Variable	Categorias	Moda	Frecuencia_moda
default	2	good	700


Table 5: Frecuencias de variables categóricas

Variable	Categoria	n	Porcentaje
checking_status	0_200	269	26.9
checking_status	greater_200	63	6.3
checking_status	less_0	274	27.4
checking_status	no_account	394	39.4
credit_history	all_paid	49	4.9
credit_history	critical_other	293	29.3
credit_history	delay	88	8.8
credit_history	existing_paid	530	53.0
credit_history	no_credit_all_paid	40	4.0
default	bad	300	30.0
default	good	700	70.0
employment	1_4	339	33.9
employment	4_7	174	17.4
employment	greater_7	253	25.3
employment	less_1	172	17.2
employment	unemployed	62	6.2
foreign_worker	yes	963	96.3
foreign_worker	no	37	3.7
housing	for_free	108	10.8
housing	own	713	71.3
housing	rent	179	17.9
job	management_self_employed_highly_qualified	148	14.8
job	skilled_official	630	63.0
job	unemployed_unskilled	22	2.2
job	unskilled_resident	200	20.0
other_debtors	co_applicant	41	4.1
other_debtors	guarantor	52	5.2
other_debtors	none	907	90.7
other_installment_plans	none	814	81.4
other_installment_plans	bank	139	13.9
other_installment_plans	stores	47	4.7
personal_status_sex	female_divorced_separated_married	310	31.0
personal_status_sex	male_divorced_separated	50	5.0
personal_status_sex	male_married	92	9.2
personal_status_sex	male_single	548	54.8
property	building_society_savings_life_insurance	232	23.2
property	car_or_other	332	33.2
property	real_estate	282	28.2
property	unknown_no_property	154	15.4
purpose	business	97	9.7
purpose	car_new	234	23.4
purpose	car_used	103	10.3
purpose	domestic_appliances	12	1.2
purpose	education	50	5.0
purpose	furniture_equipment	181	18.1

Variable	Categoria	n	Porcentaje
purpose	others	12	1.2
purpose	radio_tv	280	28.0
purpose	repairs	22	2.2
purpose	retraining	9	0.9
savings	100_500	103	10.3
savings	500_1000	63	6.3
savings	greater_1000	48	4.8
savings	less_100	603	60.3
savings	unknown	183	18.3
telephone	none	596	59.6
telephone	yes	404	40.4


A continuación se presentan las gráficas de barras para las variables categóricas asociadas a aspectos financieros del crédito:

Distribución de variables categóricas




Igualmente, se grafican las variables socioeconómicas de los solicitantes, lo cual también contribuye a la construcción de un perfil de riesgo:

Distribución de variables categóricas



Finalmente se establecen las características asociadas al entorno laboral como una característica relevante del individuo ya que permitiría ser un medio de solvencia para respaldar al crédito:

Características laborales y demográficas




Análisis bivariado y relación con variable target


Variables financieras y default






Distribución de default según variables sociodemográficas



Distribución de default según características laborales








Anlizar...

3. Preprocesamiento de datos

Con base en el análisis exploratorio, se presenta una alta cardinalidad en las variable purpose. Para este caso, se agruparán sus categorías por su naturaleza de la siguiente manera:

- Vehículos: `car_new`, `car_used`
- Hogar: `radio_tv`, `furniture_equipment`, `domestic_appliances`, `repairs`
- Inversión/Desarrollo: `business`, `education`, `retraining`
- Otros: `others`

A continuación, se presenta las agrupaciones y sus respectivos resultados:



Propósito del crédito y default

