

UNIVERSIDAD DEL VALLE – FACULTAD DE INGENIERIA

Asignatura: Machine Learning para gestión financiera

Profesor: Ivan Mauricio Bermudez Vera

Fecha Entrega: martes 07 de julio 6:00pm

Taller No. 2

Preprocesamiento y visualización de datos

Objetivo

Construir y evaluar diferentes modelos de clasificación para predecir el comportamiento crediticio de los clientes, utilizando la variable default como variable objetivo. Se espera que el estudiante aplique los conceptos vistos en clase sobre regresión logística, árboles de clasificación y random forest, comparando el desempeño de los diferentes métodos y analizando sus ventajas y limitaciones.

1. Preparación de los datos

Utilice la versión depurada de la base de datos obtenida en el Taller No. 1. Verifique la codificación de las variables, defina la variable objetivo y las variables explicativas, divida los datos en entrenamiento y prueba y justifique la partición utilizada.

2. Construcción de clasificador

Construya tres clasificadores:

- Regresión Logística
- Árbol de Clasificación
- Random Forest

2.1. Regresión logística:

- a. Construya un modelo saturado incluyendo todas las variables explicativas.
- b. Realice un proceso de selección de variables hasta obtener un modelo reducido
- c. El modelo final debe cumplir simultáneamente:
 - Variables estadísticamente significativas.
 - Ausencia de problemas importantes de multicolinealidad.
 - Justificación de cada decisión tomada.
- d. Interprete coeficientes y Odds Ratio.
- e. Evalúe el desempeño del modelo mediante métricas de clasificación.

2.2. Árbol de Clasificación:

- a. Construya el árbol de clasificación.
- b. Interprete las principales reglas de decisión.
- c. Analice la complejidad y realice poda cuando sea necesario.
- d. Identifique las variables más relevantes.
- e. Evalúe el desempeño del modelo.

2.3. Random Forest

- a. Construya un modelo Random Forest.
- b. Justifique los hiperparámetros utilizados.
- c. Reporte e interprete el error OOB.
- d. Analice la importancia de variables.
- e. Evalúe el desempeño del modelo.

3. Comparación de Modelos

Compare los tres clasificadores. Utilice como mínimo: Matriz de confusión, Accuracy, Sensitivity, Specificity, Balanced Accuracy.

Discuta fortalezas, debilidades y recomiende el mejor modelo para el problema.

Recomendaciones:

- No se limite a presentar tablas o gráficos; analice e interprete los resultados obtenidos, destacando los hallazgos más relevantes.
- El informe debe presentar una secuencia lógica y coherente, describiendo claramente cada una de las etapas desarrolladas y las decisiones tomadas durante el análisis.
- Las conclusiones deben sustentarse en la evidencia presentada a lo largo del informe.

En el campus virtual ud debe subir dos archivos:

- i. Informe escrito en PDF o html (Rmd).
- ii. Soporte: archivo Script de R o Rmd.